Wyjaśnialny asystent lekarza - symulacja

Barbara Jankowska, Krystian Kaliś

27.01.2026

Cel Projektu

- Edukacyjna symulacja wyjaśnialnego "asystenta lekarza"
- Dane: 100 syntetycznych opisów objawów z nadanymi kategoriami: PILNE, DO LEKARZA, DO OBSERWACJI, RACZEJ BŁAHE
- Dla każdego przypadku model zwraca kategorię oraz krótkie uzasadnienie decyzji
- Wyjaśnialność: Chain-of-Thought, Self-Critique, podkreślanie kluczowych objawów w opisie, analiza typowych błędów
- Porównanie dwóch modeli open-source: Llama 3.1 i Gemma 2

Pierwszy prompt i ocena jakości modeli

Pierwsze wywołanie: przypisanie jednej z kategorii dla każdego ze 100 przypadków oraz krótkie wytłumaczenie.

Tabela: Porównanie jakości modeli Llama 3.1 oraz Gemma 2

	Llama 3.1			**Gemma 2**		
Klasa	**Pre.**	**Rec.**	**F1**	**Pre.**	**Rec.**	**F1**
PILNE	0.94	0.60	0.73	0.96	0.92	0.94
DO LEKARZA	0.50	0.92	0.65	0.92	0.92	0.92
DO OBSERWACJI	0.48	0.60	0.54	0.61	0.80	0.69
RACZEJ BŁAHE	0.71	0.20	0.31	0.72	0.52	0.60
Accuracy		**0.58**			**0.79**	

Macierz pomyłek - Llama

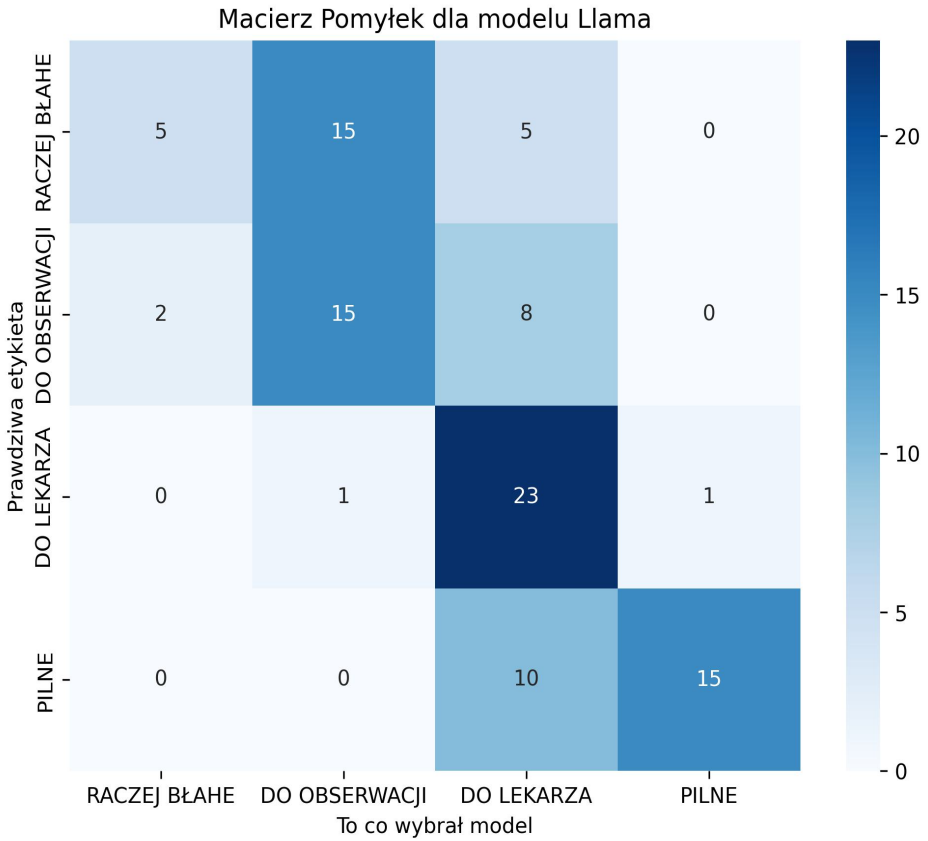

- Często zawyża powagę mniej istotnych przypadków (ostrożny model).
- Część przypadków pilnych zaniża do „do lekarza”.
- Najczęściej przewidywana klasa: „do lekarza”.

Macierz pomyłek - Gemma

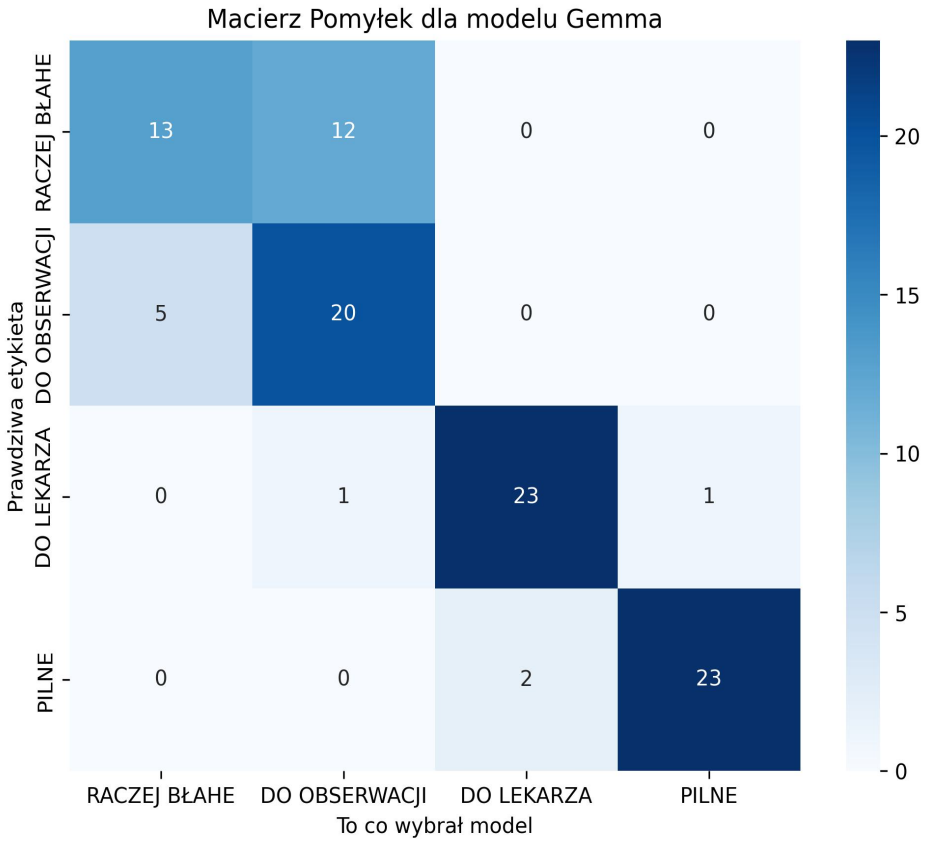

- Prawie idealna klasyfikacja przypadków poważnych (23/25).
- Drobne pomyłki przy przypadkach błahych i „do obserwacji”.
- Błędy maksymalnie o jeden poziom powagi.

Kategorie wybierane przez modele

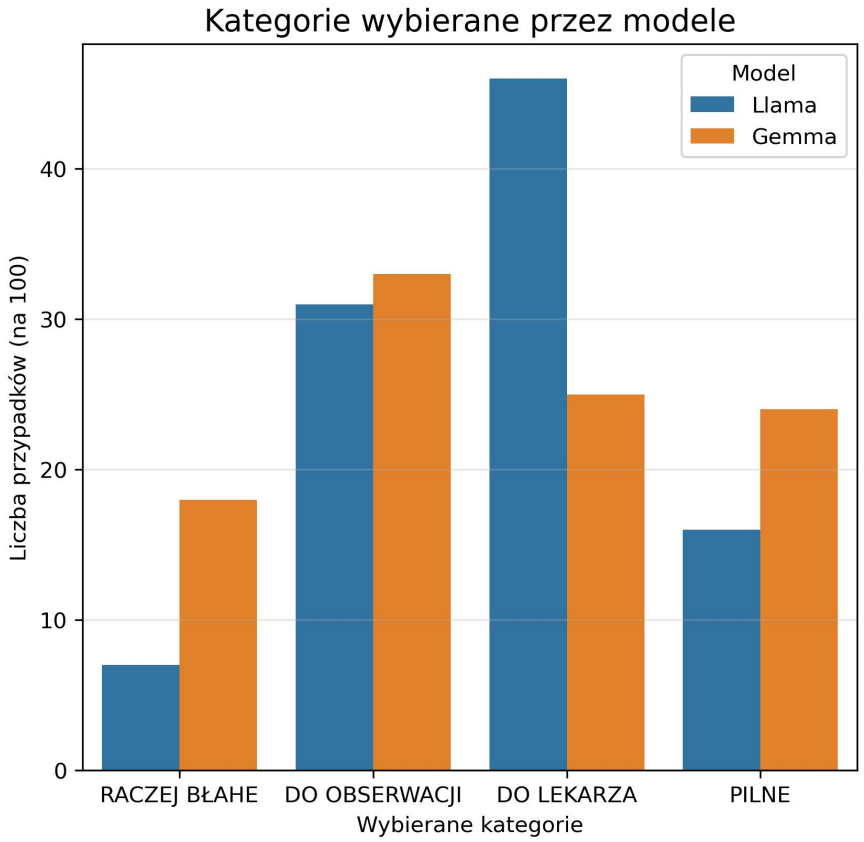

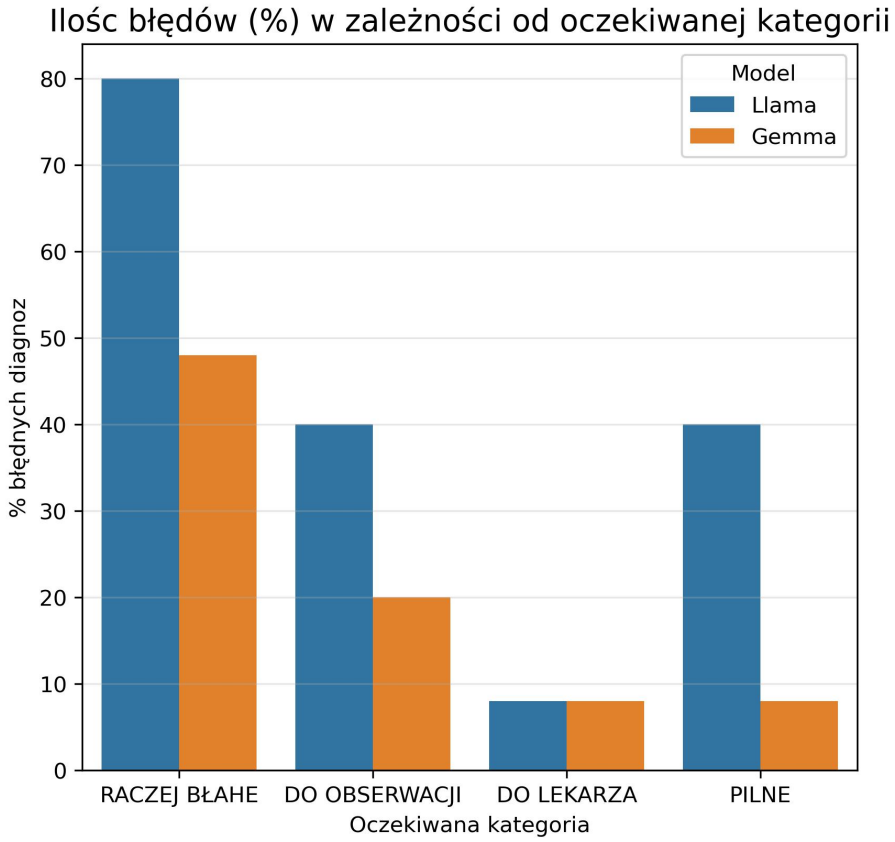

- Skrajne kategorie (PILNE/BŁAHE) wybierane są rzadko
- Llama najczęściej wybiera bezpieczną opcję „DO LEKARZA”
- Gemma rozkłada odpowiedzi niemal po równo między kategorie
- Najwięcej pomyłek: RACZEJ BŁAHE, najmniej: DO LEKARZA

Porównanie poprawności i zgodności modeli

Przypadek	**Liczba**
Oba modele miały rację	55
Oba modele się pomyliły	18
Llama miała rację, Gemma nie	3
Gemma miała rację, Llama nie	24
Miały to samo zdanie	68
Miały odmienne zdanie	32

Drugie wywołanie i wyjaśnialność

- Dodanie elementów wyjaśnialności
- Chain-of-Thought (rekonstrukcja rozumowania)
- Self-Critique: ocena swojej pierwotnej odpowiedzi w skali od 0 do 100 oraz wskazanie potencjalnych błędów
- Podświetlanie kluczowych wyrazów z opisu objawów

Przykład 1 - Llama

Pacjent #2

OCENA AI: 60/100

MODEL
PILNE

PRAWDA
PILNE

ANALIZA OBJAWÓW

Nagłe osłabienie prawej strony ciała, **opadanie kącika ust**, **problemy** z **mową**, objawy pojawiły się godzinę temu.

Wyjaśnienie pierwotne modelu

"Obserwowane objawy mogą wskazywać na poważne schorzenie, takie jak zawał lub udar."

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** Analizując logikę zawartą w poprzedniej odpowiedzi, widzę, że pacjent doświadcza nagłego osłabienia prawej strony ciała, co może sugerować problem z nerwami lub układem krążenia. Dodatkowo opadanie kącika ust i problemy z mową mogą wskazywać na zespół udarowy (naciek naczyniowo-żylakowy), jednak brakuje w tej odpowiedzi bardziej szczegółowej analiza obuwaru objawów.

🔍 **Auto-krytyka (Self-Critique):** Może pacjent doświadczył innych schorzeń, które także powodują podobne objawy. Warto rozważyć takie przypadki, jak: udar mózgu, zawał płuc lub ciężkie połamanie.

Przykład 1 - Gemma

Pacjent #2

OCENA AI: **90/100**

MODEL	PRAWDA
PILNE	**PILNE**

ANALIZA OBJAWÓW

Nagłe osłabienie prawej strony ciała, **opadanie kącika ust**, **problemy** z **mową**, objawy pojawiły się godzinę temu.

Wyjaśnienie pierwotne modelu

"Objawy wskazują na potencjalny udar mózgu, wymagający natychmiastowej pomocy medycznej w szpitalu."

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** Odpowiedź stwierdza, że objawy pacjenta wskazują na potencjalny udar mózgu. To rozumowanie opiera się na założeniu, że opisane przez pacjenta dolegliwości (osłabienie prawej strony ciała, opadanie kącika ust, problemy z mową) są charakterystyczne dla udaru.

🔍 **Auto-krytyka (Self-Critique):** Możliwe pomylenie z innym schorzeniem o podobnych objawach np. napadami padaczkowymi. Brak szczegółów medycznych utrudnia precyzyjną diagnozę.

Przykład 1 - obserwacje

- Oba modele prawidłowo oceniły przypadek jako pilny (prawdopodobnie udar)
- Jeden z niewielu przypadków pilnych, który LLama oceniła prawidłwo
- Model Gemma był bardziej pewny swojej odpowiedzi (90/100) niż Llama (60/100)

Przykład 2 - Llama

Pacjent #81

OCENA AI: **40/100**

MODEL
RACZEJ BŁAHE

PRAWDA
RACZEJ BŁAHE

ANALIZA OBJAWÓW

Niewielkie zaczerwienienie skóry po **słońcu**.

Wyjaśnienie pierwotne modelu

"Zaczerwienienie jest spowodowane przez narażenie na słońce i nie powinno powodować żadnych poważnych problemów zdrowotnych."

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** Logika zawarta w poprzedniej odpowiedzi polega na tym, że pacjent opisał objaw "niewielkie zaczerwienienie skóry po słońcu", co zostało automatycznie przypisane do naturalnego i niegroźnego procesu spowodowanego przez narażenie na słońce. Nie wykonano bardziej szczegółowej analizy, ani rozważenia możliwych poważniejszych skutków zdrowotnych.

🔍 **Auto-krytyka (Self-Critique):** Możliwe pomylenie z: W niektórych przypadkach zaczerwienienie może być sygnałem alarmowym na poważniejsze choroby skórne, takie jak trądzik różowy, czy rak. Nie uwzględniono również wskazania do sprawdzenia historii lekarskiej pacjenta, czy może mieć predyspozycje do chorób skóry.

Przykład 2 - Gemma

Pacjent #81

OCENA AI: 60/100

MODEL
RACZEJ BŁAHE

PRAWDA
RACZEJ BŁAHE

ANALIZA OBJAWÓW

Niewielkie zaczerwienienie skóry po **słońcu**.

Wyjaśnienie pierwotne modelu

"Zaczerwienienie po słońcu jest powszechnym, łagodnym i przemijającym objawem."

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** Odpowiedź zakłada, że każde zaczerwienienie skóry po słońcu jest łagodnym i przemijającym objawem. Nie bierze pod uwagę ewentualnych innych przyczyn zaczerwienienia ani stopnia jego nasilenia.

🔍 **Auto-krytyka (Self-Critique):** Możliwe pomylenie z alergią słoneczna lub oparzeniem słonecznym, które wymagają bardziej szczegółowych działań niż zwykłe łagodzenie. Nie uwzględniono stopnia zaczerwienienia ani innych objawów.

Przykład 2 - obserwacje

- Oba modele prawidłowo oceniły przypadek jako błahy
- Llama krytycznie oceniła siebie podczas self-critique (40/100)
- Podczas auto-krytyki oba modele zaczęły podejrzewać poważniejsze choroby skóry

Przykład 3 - Llama

Pacjent #15

OCENA AI: 40/100

MODEL
DO LEKARZA

PRAWDA
PILNE

ANALIZA OBJAWÓW

Wysoka gorączka u dziecka, **sztywność karku**, nadwrażliwość na światło.

Wyjaśnienie pierwotne modelu

"Objawy mogą wskazywać na infekcję podniebienia lub gardła, która wymaga diagnostyki i odpowiedniej terapii."

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** W odpowiedzi na objawy pacjenta (gorączka, sztywność karku i nadwrażliwość na światło) autor próbował zinterpretować je jako infekcję podniebienia lub gardła. Jednak niektóre z tych objawów mogą wskazywać na bardziej poważne choroby, takie jak zapalenie opon mózgowych czy meningoencefalitis.

🔍 **Auto-krytyka (Self-Critique):** Pominięto możliwość zdiagnozowania bardziej poważnych chorób

Przykład 3 - Gemma

Pacjent #15

OCENA AI: 80/100

MODEL
PILNE

PRAWDA
PILNE

ANALIZA OBJAWÓW

Wysoka gorączka u dziecka, **sztywność karku**, **nadwrażliwość** na **światło**.

Wyjaśnienie pierwotne modelu

"Objawy takie jak wysoka gorączka, sztywność karku i nadwrażliwość na światło mogą wskazywać na meningit, stan wymagający natychmiastowej pomocy medycznej."

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** Odpowiedź oparła się na rozumowaniu, że podane objawy (wysoka gorączka, sztywność karku, nadwrażliwość na światło) mogą być charakterystyczne dla meningitu. W związku z tym zalecono natychmiastową pomoc medyczną.

🔍 **Auto-krytyka (Self-Critique):** Pomimo że podane objawy są częściowo zgodne z objawami meningitu, istnieje ryzyko pomylenia z innymi chorobami, takimi jak grypa, zapalenie opon mózgowych czy zatrucie. Brakuje szczegółów u pacjenta, aby jednoznacznie postawić diagnozę.

Przykład 3 - obserwacje

- Gemma dobrze ocenia przypadek jako PILNY, a Llama błędnie jako DO LEKARZA
- Jeden z wielu podobnych przypadków. Llama rzadko określa przypadki jako PILNE, a często jako DO LEKARZA
- Llama ocenia przypadek jako infekcję gardła, mimo że objawy na to nie wskazują
- Podczas ponownego wywołania i auto-krytyki model Llama uznaje, że zbagatelizował problem (ocena 40/100) i wskazuje na te samą chorobę co Gemma (meningit)

Przykład 4 - Llama

Pacjent #58

OCENA AI: **40/100**

MODEL	PRAWDA
DO OBSERWACJI	**DO OBSERWACJI**

ANALIZA OBJAWÓW

Okresowe kołatanie serca w **sytuacjach stresowych**.

Wyjaśnienie pierwotne modelu

"Około 40% populacji doświadcza okresowego zwiększenia częstości uderzeń serca w czasie stresu lub emocji intensywnych, ale nie powinno ono stanowić żadnego poważniejszego problemu zdrowotnego."

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** W odpowiedzi na opis okresowego kołatania serca w sytuacjach stresowych, autorstwa pomyślał, że jest to doświadczone przez około 40% populacji. Uznał więc, że nie powinno ono stanowić żadnego poważniejszego problemu zdrowotnego. Jednak ten wniosek nie uwzględnia możliwości występowania u pacjenta bardziej powikłanych objawów.

🔍 **Auto-krytyka (Self-Critique):** Możliwe pomylenie z bezpiecznym i niegroźnym stanem, jednak nie wzięto pod uwagę potencjalnych innych przyczyn objawów pacjenta.

Przykład 4 - Gemma

Pacjent #58

OCENA AI: 60/100

MODEL
RACZEJ BŁAHE

PRAWDA
DO OBSERWACJI

ANALIZA OBJAWÓW

Okresowe kołatanie serca w sytuacjach stresowych.

Wyjaśnienie pierwotne modelu

"Kołatanie serca w stresujących momentach jest częstym objawem, który zazwyczaj nie stanowi zagrożenia dla zdrowia."

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** Odpowiedź zakłada, że kołatanie serca w stresujących momentach jest zjawiskiem naturalnym i zazwyczaj niegroźnym.

🔍 **Auto-krytyka (Self-Critique):** Możliwe pomylenie z bardziej poważnymi problemami kardiologicznymi, które mogą się objawiać kołataniami serca. Brak informacji o częstotliwości i intensywności kołatania.

Przykład 4 - obserwacje

- Jeden z nielicznych (3) przypadków, kiedy model Llama odpowiedział dobrze, a Gemma źle
- Llama ocenia swoją odpowiedź na 40/100, a Gemma na 60/100, mimo, że to Llama dała dobrą odpowiedź
- W tym przypadku Gemma przecenia swoją odpowiedź, a Llama jest wobec siebie zbyt krytyczna

Przykład 5 - Llama

Pacjent #60

OCENA AI: 70/100

MODEL
DO LEKARZA

PRAWDA
DO OBSERWACJI

ANALIZA OBJAWÓW

Przemijający ból pleców po **długim siedzeniu**.

Wyjaśnienie pierwotne modelu

"Ból pleców może być objawem wielu różnych problemów, więc najlepiej sprawdzić u lekarza, aby wykluczyć poważniejsze przyczyny."

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** Pacjent doświadcza przemijającego bólu pleców po długim siedzeniu, co sugeruje, że może mieć problemy z kręgosłupem lub mięśniami. Odpowiedź sugerowała sprawdzenie u lekarza, aby wykluczyć poważniejsze przyczyny. Wydaje się to rozsądkowe, ponieważ ból pleców może mieć wiele różnych przyczyn, a lekarz ma dostęp do pełnej diagnozy.

🔍 **Auto-krytyka (Self-Critique):** Możliwe pomylenie z chorobą nowotworową: "Przemijający ból pleców" może sugerować inne przyczyny niż poważne, ale nie wyklucza choroby nowotworowej. Warto by było podkreślić ryzyko istnienia nowotworu w konsultacji.

Przykład 5 - Gemma

Pacjent #60

OCENA AI: 60/100

MODEL
RACZEJ BŁAHE

PRAWDA
DO OBSERWACJI

ANALIZA OBJAWÓW

Przemijający ból pleców po długim siedzeniu.

Wyjaśnienie pierwotne modelu
"Przemijający ból pleców to częsty problem, który ustępuje po odpoczynku. Nie wymaga interwencji medycznej."

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** Odpowiedź zakłada, że przemijający ból pleców po długim siedzeniu jest powszechnym problemem, który rozwiązuje się samoistnie po odpoczynku. Nie ma w analizie innych potencjalnych przyczyn bólu ani konsekwencji.

🔍 **Auto-krytyka (Self-Critique):** Możliwe pomylenie z zwykłym dolegliwością mięśniową. Nie uwzględnia innych potencjalnych przyczyn bólu pleców, takich jak urazy, dyskopatie lub choroby autoimmunologiczne.

Przykład 5 - obserwacje

- Oba modele się pomyliły: Llama określiła przypadek jako DO LEKARZA, Gemma jako RACZEJ BŁAHE, a dobra odpowiedź była pomiędzy (DO OBSERWACJI)
- Llama jest bardzo ostrożna, sugeruje pójście do lekarza "aby wykluczyć poważniejsze przyczyny"
- Gemma zakłada, że przemijający ból jest powszechnym problemem

Przykład 6 - Llama

Pacjent #94

OCENA AI: 60/100

MODEL
DO LEKARZA

PRAWDA
RACZEJ BŁAHE

ANALIZA OBJAWÓW

Ból karku po **pracy przy komputerze**.

Wyjaśnienie pierwotne modelu

"Powyższy opis sugeruje możliwość skurczowego zapalenia mięśni (zespół napięcia mięśniowego) spowodowanego długotrwałym siedzeniem przy komputerze, ale wymaga wizyty u lekarza do przeprowadzenia bardziej szczegółowej diagnostyki."

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** Pacjent opisuje ból karku, który występuje po pracy przy komputerze. Odpowiedź sugeruje, że jest to skurczowe zapalenie mięśni (zespół napięcia mięśniowego) spowodowane długotrwałym siedzeniem przy komputerze.

🔍 **Auto-krytyka (Self-Critique):** Możliwe pomylenie z objawami nerwobólów lub innych schorzeń niezwiązanych bezpośrednio z działaniem przy komputerze. Nie wzięto pod uwagę możliwości wystąpienia innych warunków, np. zapalenia międzykręgowego czy kręgosłupa.

Przykład 6 - Gemma

Pacjent #94

OCENA AI: 60/100

MODEL
DO OBSERWACJI

PRAWDA
RACZEJ BŁAHE

ANALIZA OBJAWÓW

Ból karku po **pracy przy komputerze**.

Wyjaśnienie pierwotne modelu

"Ból karku po pracy przy komputerze jest częstym problemem, który zazwyczaj ustępuje samodzielnie. "

Analiza Krytyczna

🧠 **Analiza logiki (Chain-of-Thought):** Odpowiedź zakłada, że ból karku po pracy przy komputerze jest powszechnym problemem, który zwykle ustępuje bez specjalistycznego leczenia.

🔍 **Auto-krytyka (Self-Critique):** Możliwe pominięcie poważnych przyczyn bólu karku, które wymagają dalszego badania i leczenia. Nie biorąc pod uwagę wieku pacjenta, historii chorób czy innych potencjalnych czynników ryzyka.

Przykład 6 - obserwacje

- Oba modele się mylą i uznają przypadek za poważniejszy
- Llama bezpodstawnie diagnozuje poważną chorobę (skurczowe zapalenie mięśni) - zbyt ostrożna
- Gemma twierdzi, że to powszechny problem, który ustąpi

Porównanie dokładności oraz auto-krytyki modeli

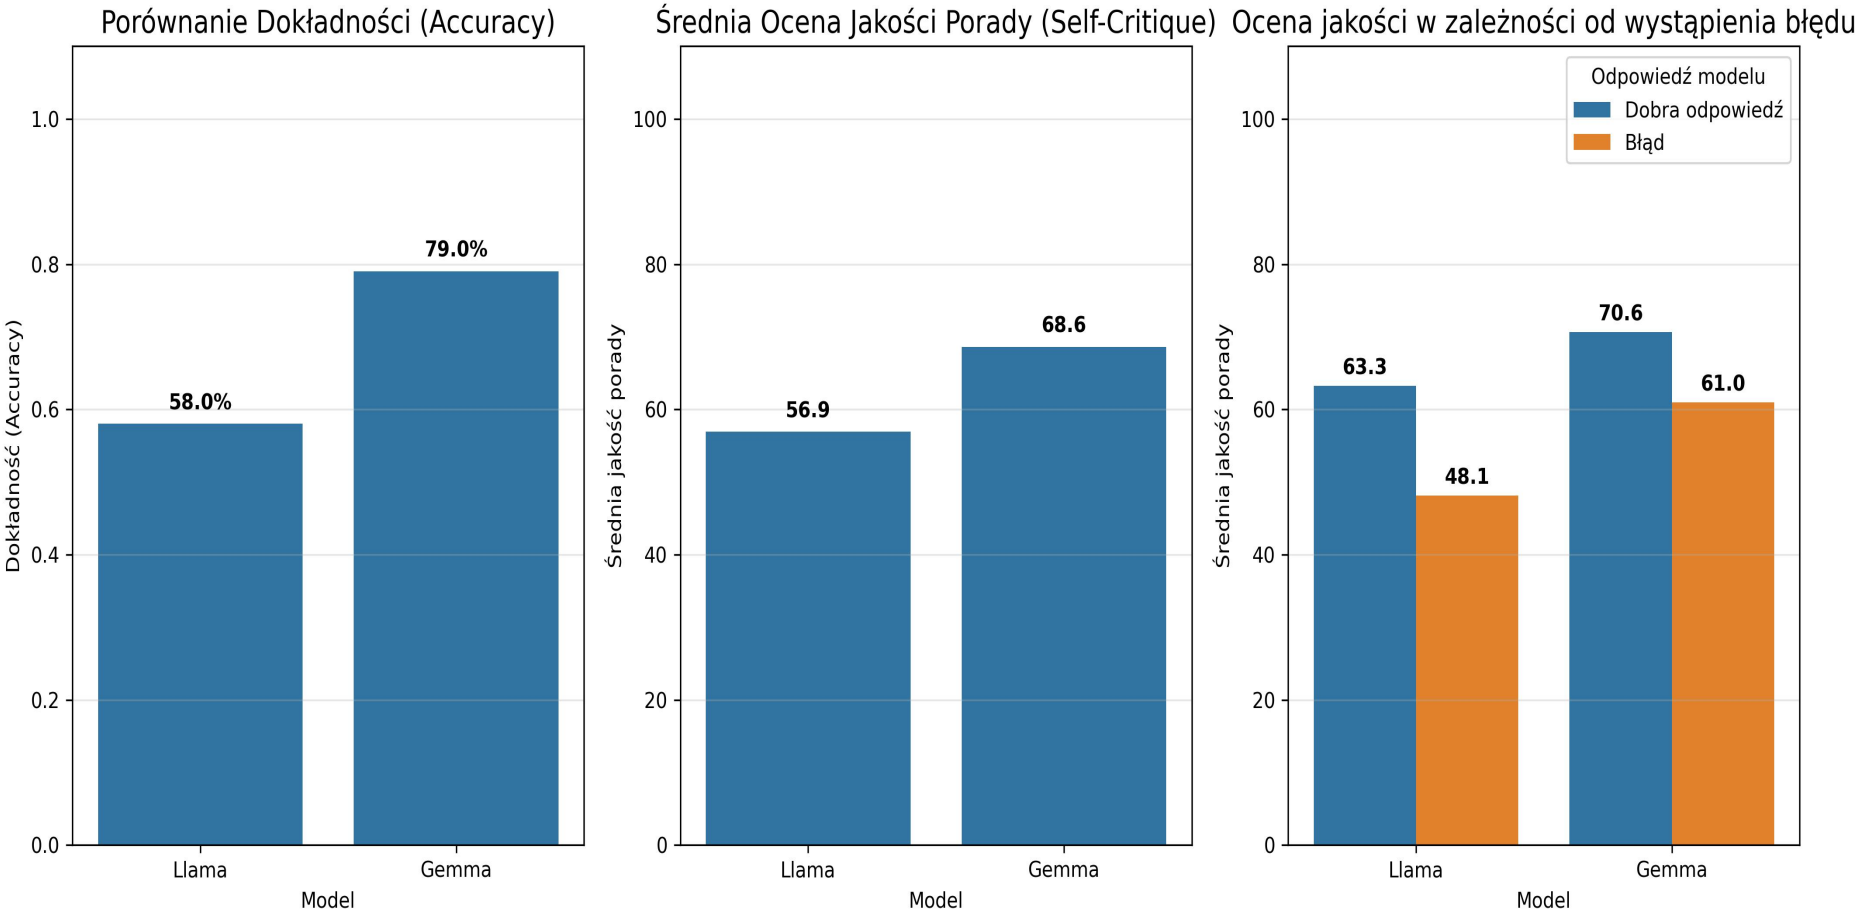

Ocena pewności modeli (z self-critique)

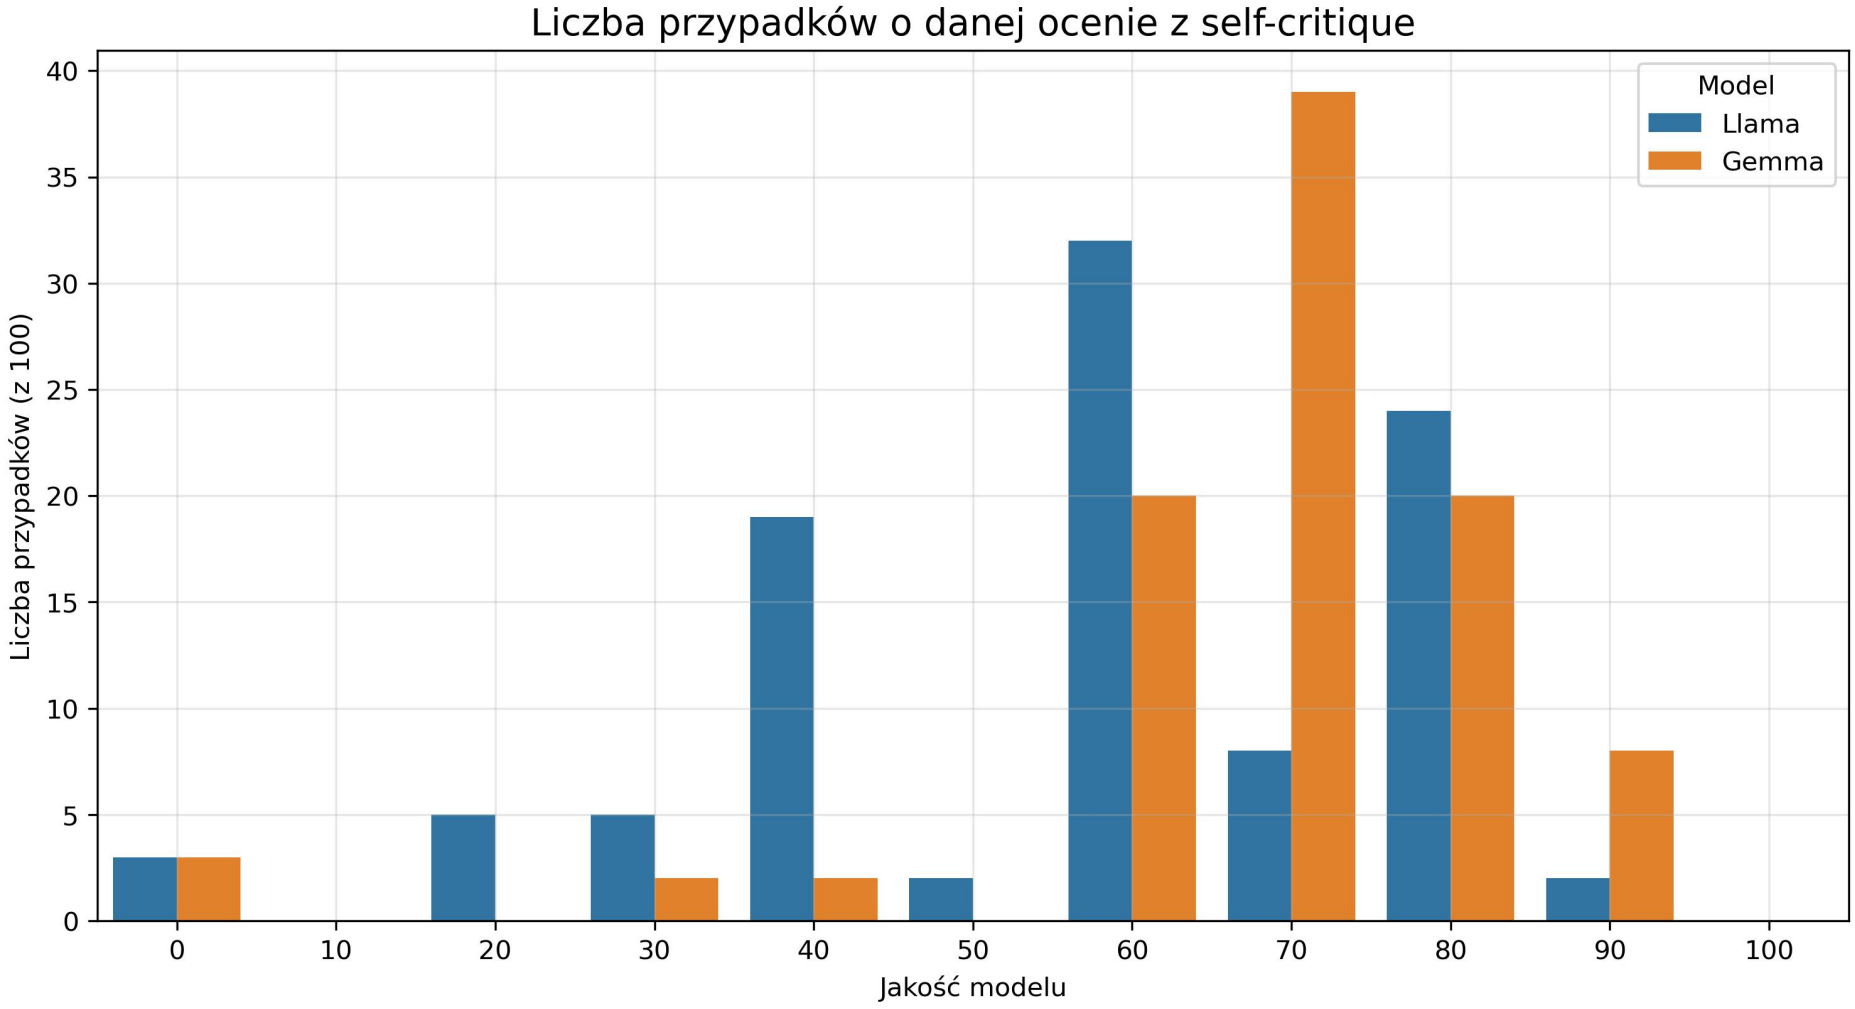

Ilość błędów a ocena pewności modeli

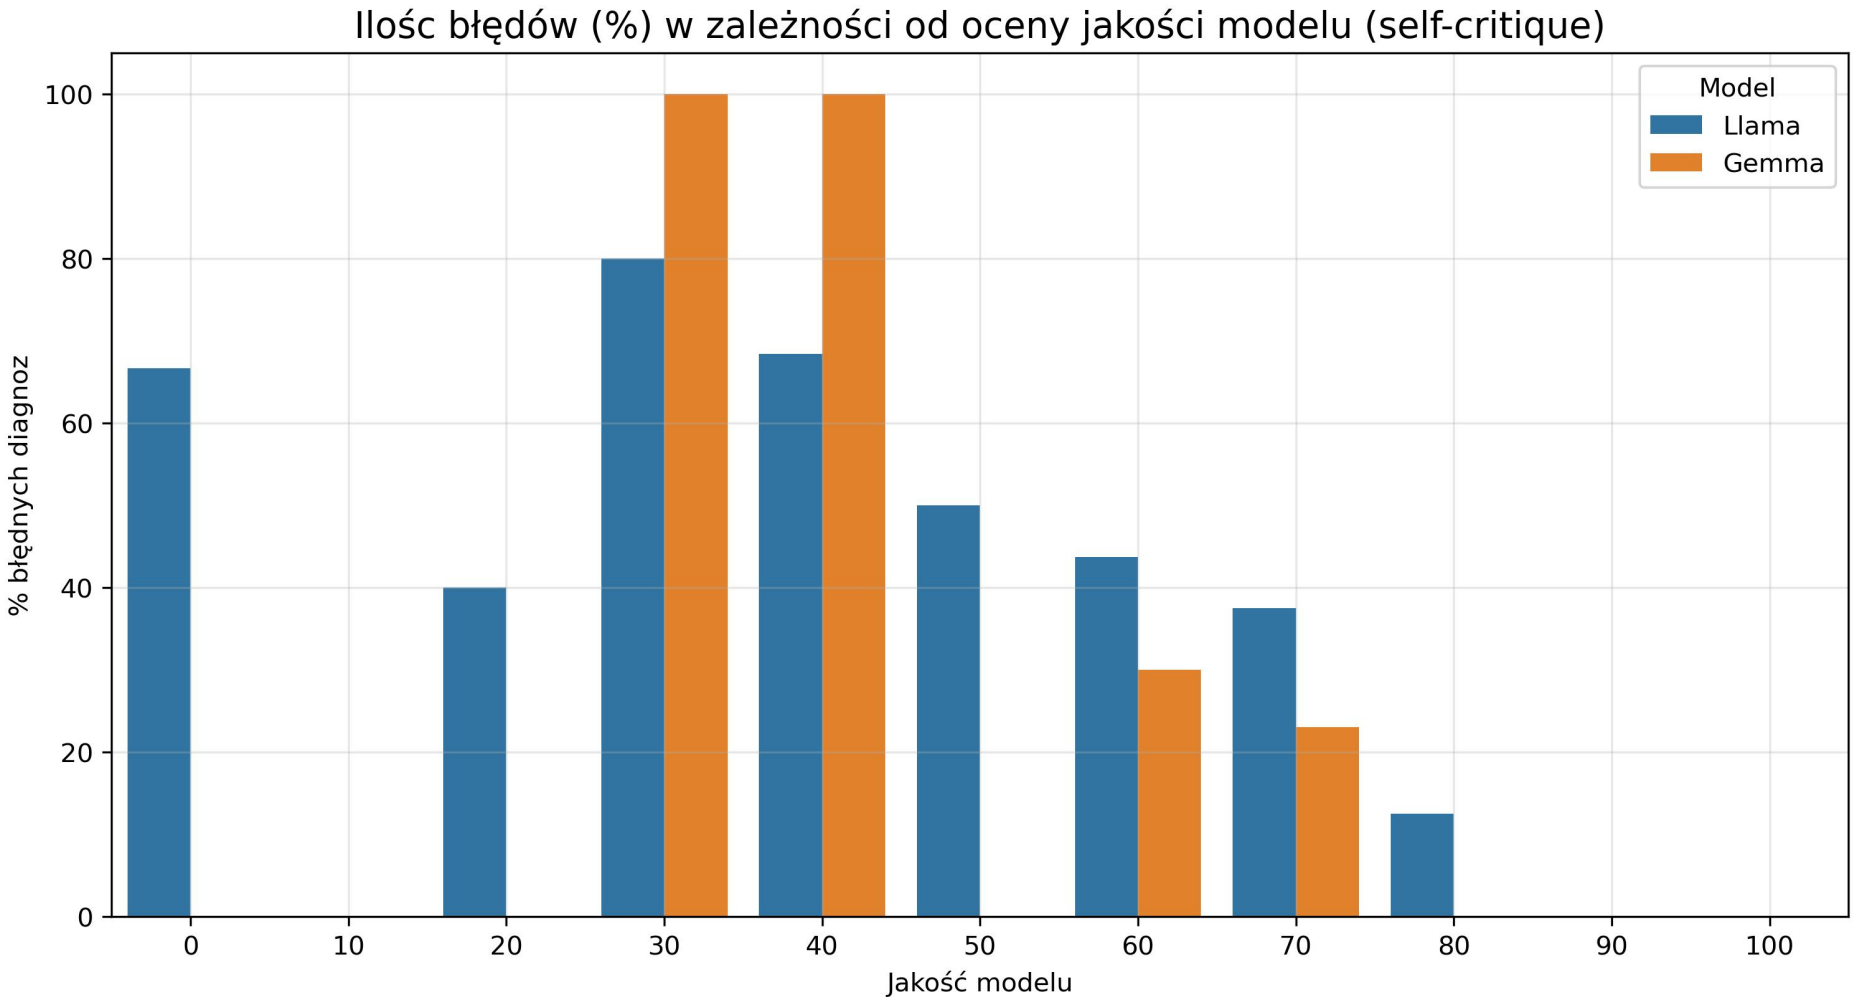

Obserwacje

- Model Llama średnio gorzej ocenia swoją pracę (średnia 56.9) niż model Gemma (średnio 68.6)
- Wszystkie przypadki, które Gemma ocenił słabo w auto-krytyce (30-40/100) okazały się faktycznymi błędami.
- Model Llama jest bardziej krytyczny wobec siebie i mniej skuteczny
- Model Gemma jest bardziej skuteczny, ale czasami zbyt pewny siebie

Wnioski końcowe

- Model Gemma 2 był bardziej skuteczny niż Llama 3.1
- Oba modele są z natury ostrożne – rzadko bagatelizują objawy, a Llama najczęściej wybiera bezpieczną opcję „DO LEKARZA”.
- Mechanizm Self-Critique pozwala modelom na trafną identyfikację własnych błędów.
- Llama jest wobec siebie bardziej krytyczna (niższe oceny własne), natomiast Gemma bywa zbyt pewna siebie, wysoko oceniając nawet błędne diagnozy.
- Wyjaśnialność poprzez podświetlanie tekstu i Chain-of-Thought ułatwia weryfikację pracy modeli.

Dziękujemy za Uwagę