Raport z projektu: Wyjaśnialny asystent lekarza (Symulacja)

Barbara Jankowska, Krystian Kaliś

Styczeń 2026 r.

UWAGA: Projekt ma charakter wyłącznie edukacyjno-badawczy. Wyniki generowane przez modele nie stanowią porady medycznej.

Spis treści

1 Definicja zadania i danych **2**
1.1 Zbiór danych 2

2 Pipeline z LLM **2**
2.1 Inżynieria promptów 2

3 Ewaluacja i wyniki **3**
3.1 Porównanie jakości modeli 3
3.2 Macierze pomyłek 3
3.3 Preferencje wyboru kategorii 4
3.4 Porównanie poprawności i zgodności modeli 4

4 Analiza szczegółowa przypadków (Success & Failure Cases) **5**
4.1 Przykład 1: Podejrzenie udaru 5
4.2 Przykład 2 6
4.3 Przykład 3 7
4.4 Przykład 4 8
4.5 Przykład 5 9
4.6 Przykład 6 10

5 Analiza zbiorcza dokładności i mechanizmu auto-krytyki **11**
5.1 Porównanie dokładności i jakości porad 11
5.2 Rozkład ocen własnych i ich wiarygodność 12
5.3 Obserwacje 13

6 Demo i Implementacja **13**

7 Wnioski końcowe **13**

1 Definicja zadania i danych

Celem projektu było stworzenie symulacji systemu wspierającego wstępną segregację pacjentów na podstawie opisów objawów. System przypisuje przypadki do jednej z czterech kategorii:

- **PILNE**: Stan zagrożenia życia lub wymagający natychmiastowej pomocy.
- **DO LEKARZA**: Wymaga konsultacji medycznej w najbliższym czasie.
- **DO OBSERWACJI**: Objawy łagodne, wymagające monitorowania.
- **RACZEJ BŁAHE**: Typowe dolegliwości niewymagające interwencji.

1.1 Zbiór danych

Przygotowano zbiór 100 syntetycznych przypadków (promptów) z ręcznie nadanymi etykietami. Każdy przykład zawierał opis pacjenta (wiek, płeć, główne dolegliwości, czas trwania objawów).

2 Pipeline z LLM

W projekcie wykorzystano i porównano dwa modele typu open-source:

1. **Llama 3.1**
2. **Gemma 2**

2.1 Inżynieria promptów

W celu realizacji zadania zbudowano dedykowany pipeline w środowisku Python. Proces przetwarzania został podzielony na dwa główne etapy: klasyfikację wstępną oraz etap pogłębionej wyjaśnialności.

- **Prompt Klasyfikacyjny:** Model otrzymuje instrukcję systemową definiującą jego rolę jako asystenta medycznego. W treści promptu zawarto definicje czterech dostępnych kategorii. Model został zobligowany do zwrócenia etykiety oraz krótkiego wyjaśnienia dla każdego ze 100 przypadków.
- **Prompt z wyjaśnialnością** W drugim wywołaniu model otrzymuje swoją poprzednią odpowiedź i jest proszony wytłumaczenie swojego rozumowania (**Chain-of-Thought** oraz o krytyczną analizę (**Self-Critique**). Instrukcja wymusza ocenę pewności diagnozy w skali 0-100 oraz wskazanie potencjalnych błędów lub alternatywnych interpretacji objawów.
- **Podświetlanie słów kluczowych:** Wykorzystano funkcje biblioteki `IPython.display.HTML`, aby w wynikowym oknie podświetlić kluczowe słowa, które bezpośrednio wpłynęły na decyzję modelu. Pozwala to użytkownikowi na natychmiastową weryfikację, czy model oparł się na istotnych medycznie przesłankach.

3 Ewaluacja i wyniki

Jakość klasyfikacji mierzono za pomocą metryk Accuracy, Precision, Recall oraz F1-score.

3.1 Porównanie jakości modeli

Tabela 1: Porównanie metryk jakościowych modeli

	Llama 3.1			**Gemma 2**		
Klasa	**Pre.**	**Rec.**	**F1**	**Pre.**	**Rec.**	**F1**
PILNE	0.94	0.60	0.73	0.96	0.92	0.94
DO LEKARZA	0.50	0.92	0.65	0.92	0.92	0.92
DO OBSERWACJI	0.48	0.60	0.54	0.61	0.80	0.69
RACZEJ BŁAHE	0.71	0.20	0.31	0.72	0.52	0.60
Accuracy		**0.58**			**0.79**	

Gemma 2 okazała się znacznie skuteczniejsza (Accuracy: 0.79) niż Llama 3.1 (0.58). Llama wykazywała tendencję do nadmiernej ostrożności, często przypisując kategorię "DO LEKARZA"nawet w błahych przypadkach (o czym świadczy niski wynik Precision oraz wysoki wynik Recall dla tej kategorii).

3.2 Macierze pomyłek

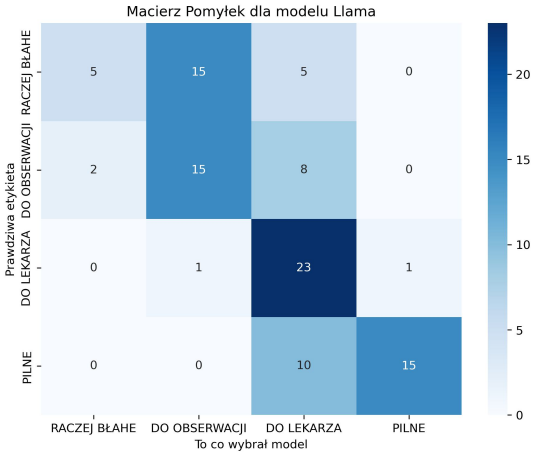

Rysunek 1: Macierz pomyłek - Llama 3.1

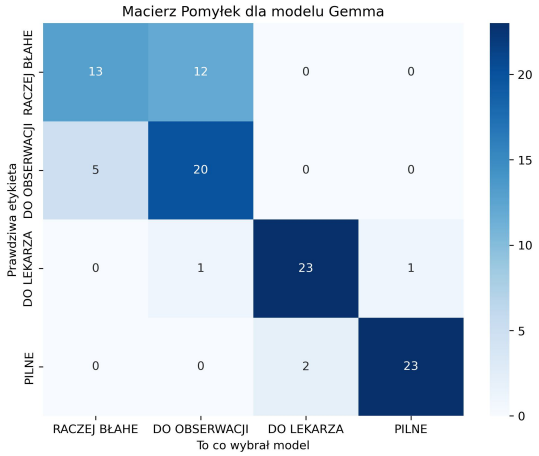

Rysunek 2: Macierz pomyłek - Gemma 2

- **Llama 3.1:** Model wykazuje cechy asystenta nadmiernie ostrożnego. Często zawyża powagę mniej istotnych przypadków, kierując je do wyższych kategorii (zazwyczaj "do lekarza"). Jednocześnie odnotowano tendencję do zaniżania części przypadków faktycznie pilnych do kategorii „do lekarza”.

- **Gemma 2:** Model cechuje się wysoką precyzją w stanach krytycznych – poprawnie sklasyfikował 23 na 25 przypadków poważnych. Ewentualne pomyłki dotyczą głównie kategorii błahych oraz „do obserwacji", przy czym błędy te zawsze ograniczają się do przesunięcia o jeden poziom w skali powagi.

3.3 Preferencje wyboru kategorii

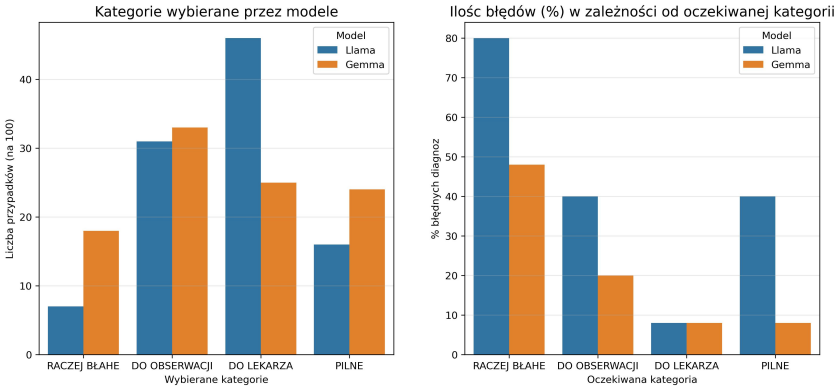

Rysunek 3: Rozkład kategorii wybieranych przez poszczególne modele.

- Modele rzadko decydują się na wskazanie skrajnych kategorii (PILNE lub BŁAHE).
- Model Llama najczęściej wybiera "bezpieczny środek", czyli opcję **DO LEKARZA**.
- Model Gemma rozkłada odpowiedzi w sposób bardziej zrównoważony i niemal równomierny między dostępne kategorie.
- Statystycznie najwięcej pomyłek w obu systemach generuje kategoria **RACZEJ BŁAHE**, natomiast najmniej błędów pojawia się przy klasie **DO LEKARZA**.

3.4 Porównanie poprawności i zgodności modeli

Zestawienie bezpośrednie wyników na tym samym zbiorze 100 przypadków pozwala określić stopień korelacji między modelami:

Tabela 2: Statystyka zgodności i poprawności diagnoz

Kategoria porównawcza	**Liczba przypadków**
Oba modele miały rację	55
Oba modele się pomyliły	18
Llama miała rację, Gemma nie	3
Gemma miała rację, Llama nie	24
Modele miały to samo zdanie (zgodność)	68
Modele miały odmienne zdanie	32

Wyniki wskazują, że w ponad połowie przypadków (55%) oba modele dostarczają poprawną i zgodną diagnozę. Istotna jest jednak liczba 24 przypadków, w których tylko

model Gemma podał właściwą odpowiedź, co potwierdza jego wyższą ogólną skuteczność w tej symulacji.

4 Analiza szczegółowa przypadków (Success & Failure Cases)

W tej sekcji przedstawiono 6 wybranych przykładów, które ilustrują sposób rozumowania modeli, ich skuteczność oraz wyniki mechanizmu auto-krytyki (self-critique).

4.1 Przykład 1: Podejrzenie udaru

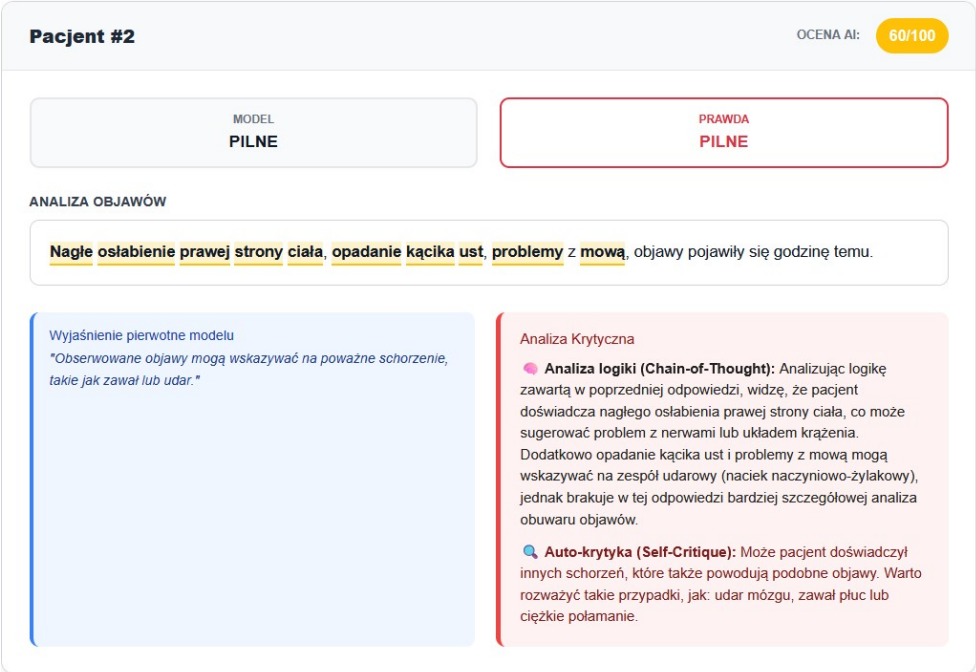

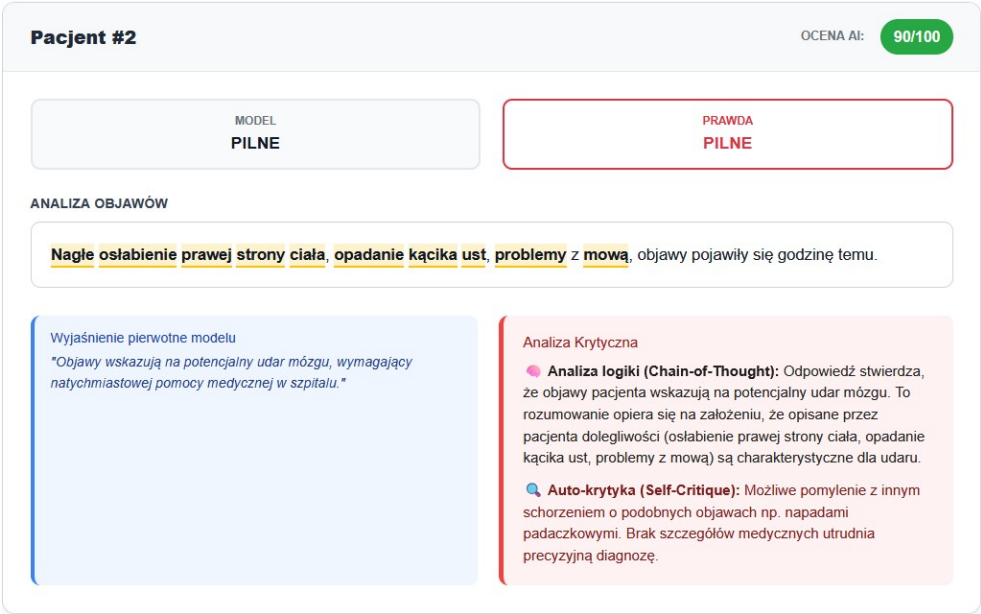

- Oba modele prawidłowo zidentyfikowały stan jako krytyczny (podejrzenie udaru).
- Jest to jeden z niewielu przypadków pilnych, w których Llama 3.1 nie zaniżyła kategorii.
- Model Gemma 2 wykazał się znacznie większą pewnością siebie (90/100) w porównaniu do Llamy (60/100).

4.2 Przykład 2

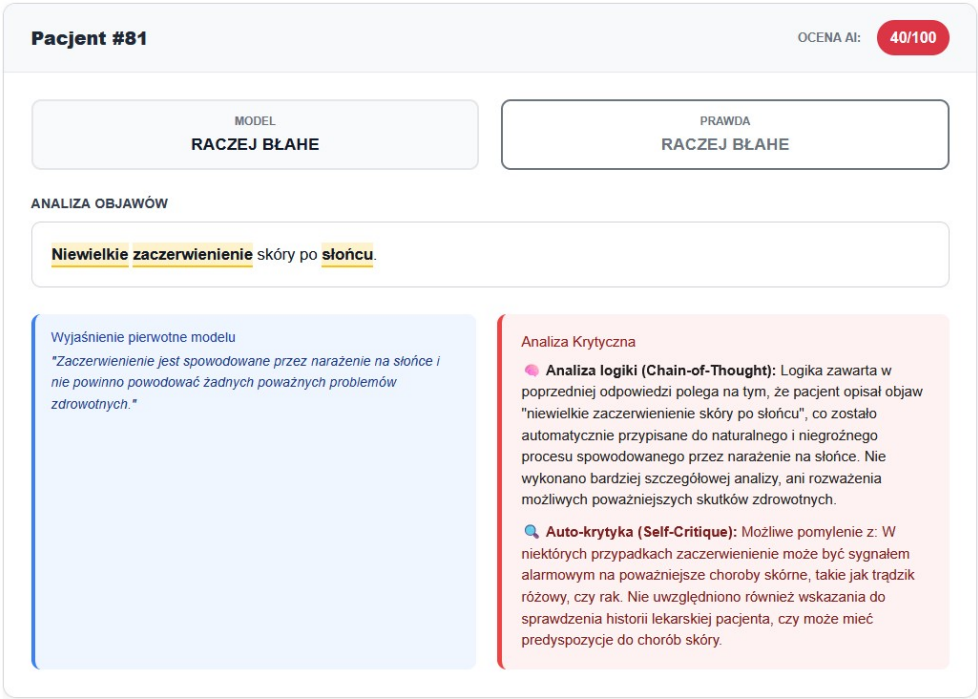

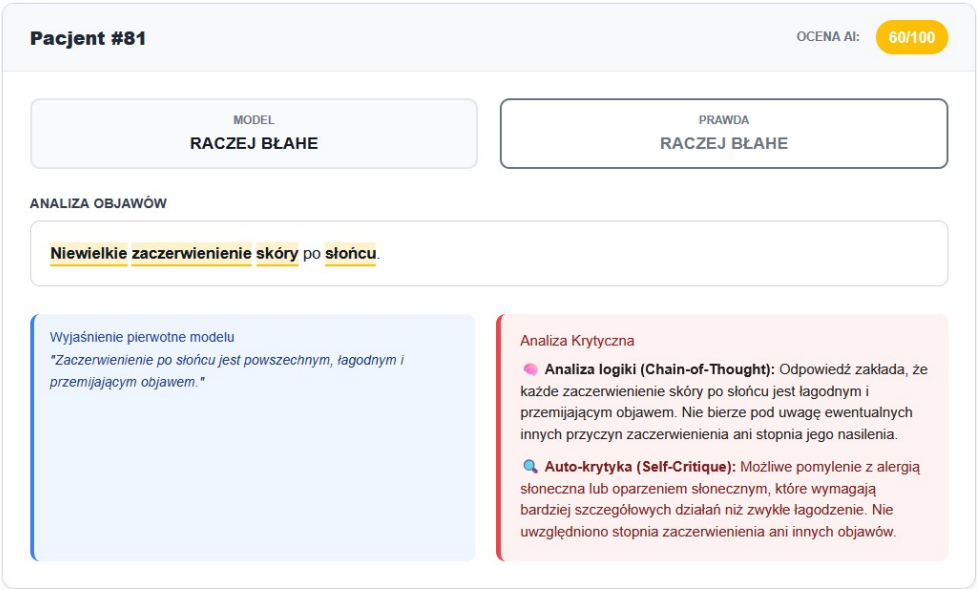

- Oba modele poprawnie oceniły przypadek jako błahy.

- W procesie auto-krytyki oba modele (zwłaszcza Llama) zaczęły wykazywać nadmierną ostrożność, podejrzewając poważniejsze schorzenia dermatologiczne.
- Llama oceniła swoją odpowiedź bardzo nisko (40/100), mimo, że zdiagnozowała pacjenta prawidłowo.

4.3 Przykład 3

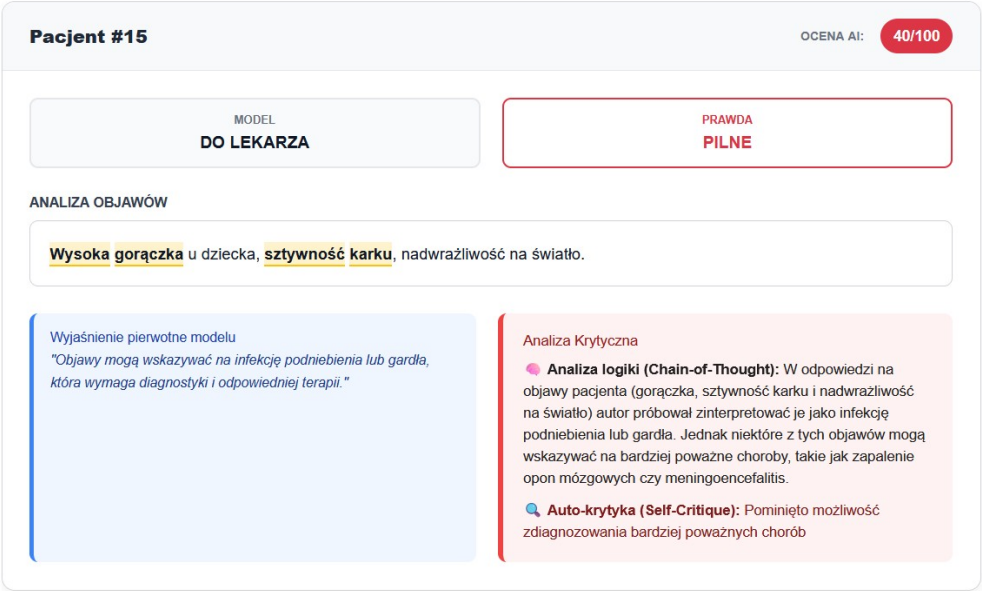

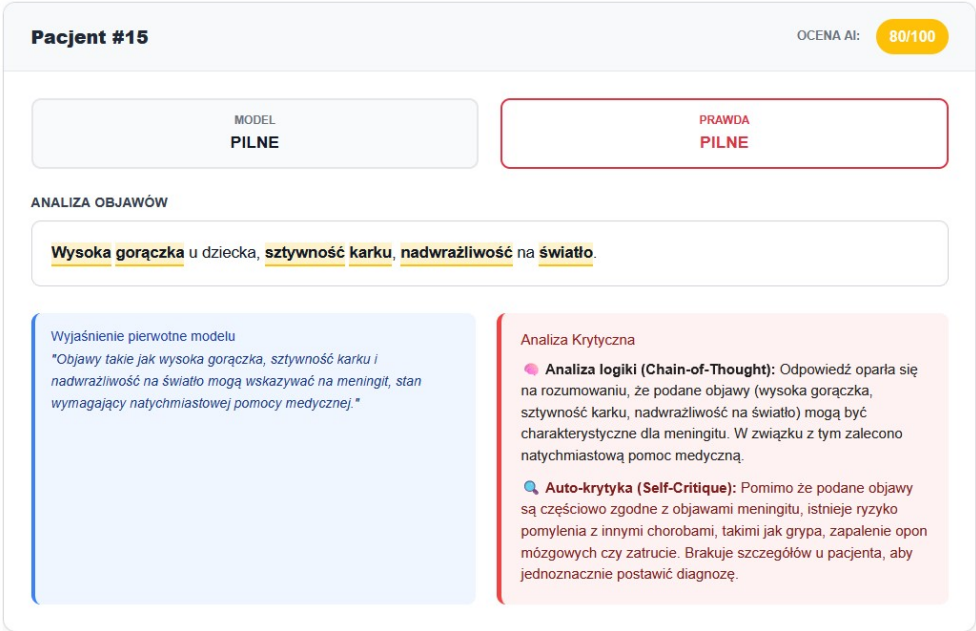

- Gemma poprawnie wskazała stan PILNY, podejrzewając chorobę meningit (zapalenie opon mózgowych).
- Llama błędnie uznała to za infekcję gardła (DO LEKARZA).

- Jest to reprezentatywny przykład dla modelu Llama, który wykazuje tendencję do unikania kategorii "pilne"na rzecz "bezpiecznej"porady lekarskiej, często ignorując przy tym alarmujące symptomy.
- Podczas ponownego wywołania i fazy auto-krytyki, Llama 3.1 wykazała zdolność do naprawy błędu. Model uznał, że zbagatelizował problem (wystawiając sobie niską ocenę (40/100) i ostatecznie wskazał na tę samą chorobę co Gemma (zapalenie opon mózgowych)

4.4 Przykład 4

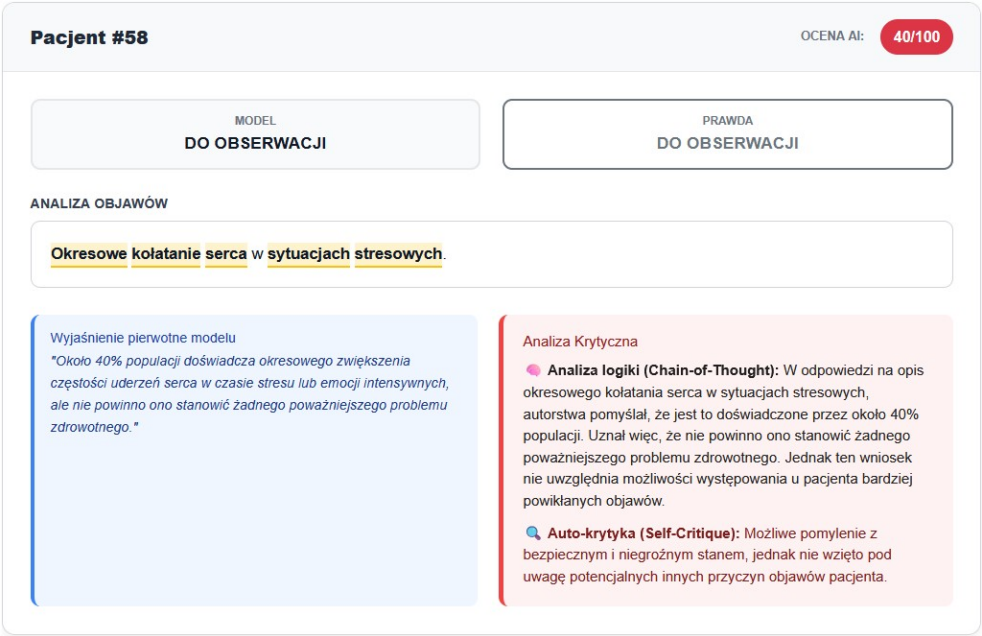

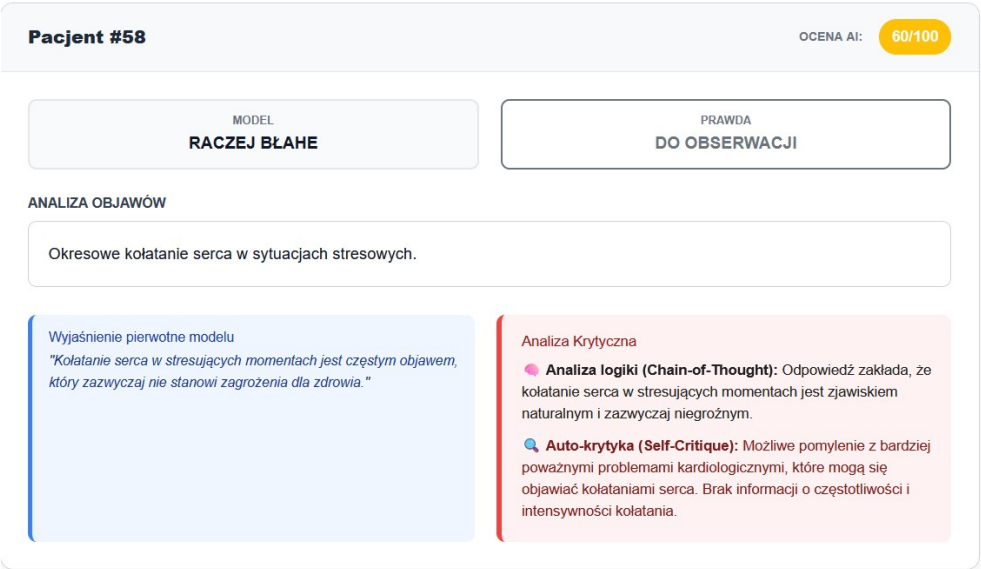

Ten przypadek jest szczególnie interesujący, ponieważ stanowi jeden z nielicznych wyjątków (zaledwie 3 na 100 testowanych przypadków), w których model Llama 3.1 poprawnie

sklasyfikował pacjenta, podczas gdy zazwyczaj skuteczniejszy model Gemma 2 popełnił błąd.

- Model Llama 3.1 trafnie zdiagnozował przypadek jako "do obserwacji". Gemma 2 ocenił przypadek jako błahy, zakładając, że jest to zjawisko częste, niezagrażające życiu.
- Mimo udzielenia poprawnej odpowiedzi, Llama 3.1 oceniła swoją pewność jedynie na **40/100**. Świadczy to o tym, że jest zbyt krytyczna wobec własnego wnioskowania, nawet gdy jest ono słuszne.
- Z kolei Gemma 2, mimo błędnej diagnozy, oceniła swoją odpowiedź na **60/100**. Jest to przykład "przecenienia"własnych kompetencji, co w zastosowaniach medycznych jest zjawiskiem potencjalnie niebezpiecznym.

4.5 Przykład 5

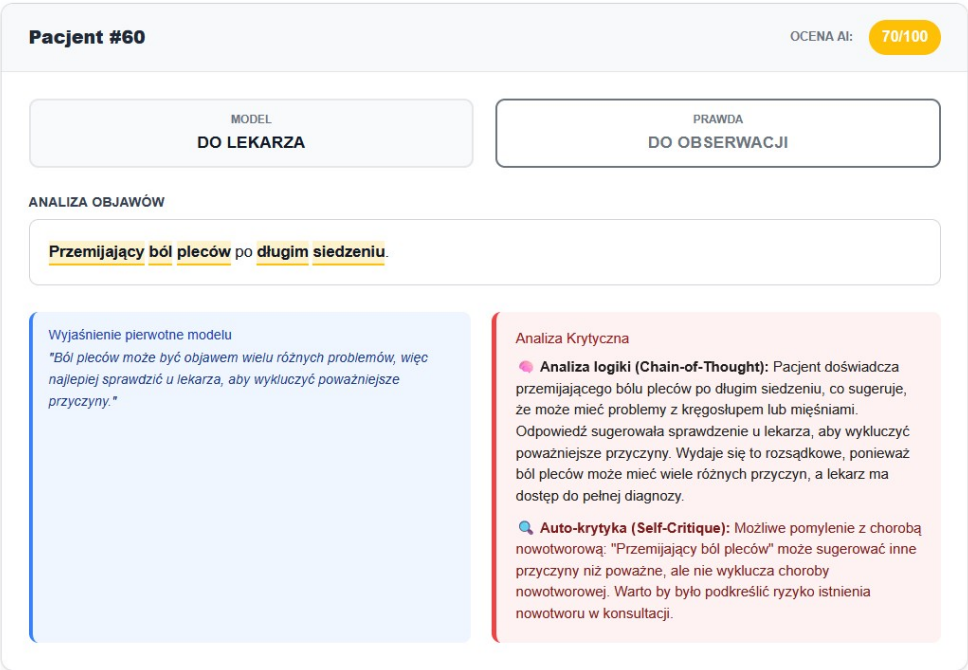

Pacjent #60 OCENA AI: 60/100

MODEL
RACZEJ BŁAHE

PRAWDA
DO OBSERWACJI

ANALIZA OBJAWÓW

Przemijający ból pleców po długim siedzeniu.

Wyjaśnienie pierwotne modelu
"Przemijający ból pleców to częsty problem, który ustępuje po odpoczynku. Nie wymaga interwencji medycznej."

Analiza Krytyczna
🧠 **Analiza logiki (Chain-of-Thought):** Odpowiedź zakłada, że przemijający ból pleców po długim siedzeniu jest powszechnym problemem, który rozwiązuje się samoistnie po odpoczynku. Nie ma w analizie innych potencjalnych przyczyn bólu ani konsekwencji.

🔍 **Auto-krytyka (Self-Critique):** Możliwe pomylenie z zwykłym dolegliwością mięśniową. Nie uwzględnia innych potencjalnych przyczyn bólu pleców, takich jak urazy, dyskopatie lub choroby autoimmunologiczne.

W tym przypadku oba modele błędnie określiły przypadek, omijając poprawną etykietę (**DO OBSERWACJI**) z dwóch różnych stron skali powagi.

- Llama 3.1 wykazała się typową dla niej nadmierną ostrożnością, kierując pacjenta **DO LEKARZA** w celu "wykluczenia poważniejszych przyczyn". Z kolei Gemma 2 zbagatelizowała objawy, uznając je za **RACZEJ BŁAHE** i przyjmując, że przemijający ból jest zjawiskiem powszechnym.
- Przykład ten ilustruje brak precyzji modeli w interpretacji stanów pośrednich, gdzie granica między obserwacją a koniecznością wizyty u specjalisty jest zatarta.

4.6 Przykład 6

Pacjent #94 OCENA AI: 60/100

MODEL
DO LEKARZA

PRAWDA
RACZEJ BŁAHE

ANALIZA OBJAWÓW

Ból karku po **pracy przy komputerze**.

Wyjaśnienie pierwotne modelu
"Powyższy opis sugeruje możliwość skurczowego zapalenia mięśni (zespół napięcia mięśniowego) spowodowanego długotrwałym siedzeniem przy komputerze, ale wymaga wizyty u lekarza do przeprowadzenia bardziej szczegółowej diagnostyki."

Analiza Krytyczna
🧠 **Analiza logiki (Chain-of-Thought):** Pacjent opisuje ból karku, który występuje po pracy przy komputerze. Odpowiedź sugeruje, że jest to skurczowe zapalenie mięśni (zespół napięcia mięśniowego) spowodowane długotrwałym siedzeniem przy komputerze.

🔍 **Auto-krytyka (Self-Critique):** Możliwe pomylenie z objawami nerwobólów lub innych schorzeń niezwiązanych bezpośrednio z działaniem przy komputerze. Nie wzięto pod uwagę możliwości wystąpienia innych warunków, np. zapalenia międzykręgowego czy kręgosłupa.

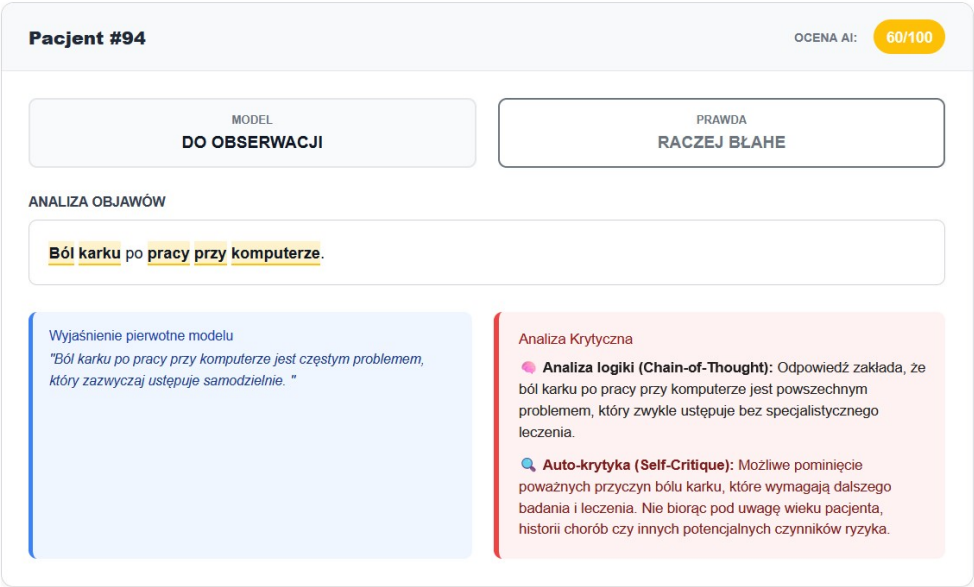

W ostatnim przykładzie oba modele popełniły błąd, przypisując dolegliwościom wyższą kategorię istotności.

- Llama 3.1 zdiagnozowała poważne schorzenie (skurczowe zapalenie mięśni), co potwierdza jej tendencję do "bezpiecznych", ale zbyt pesymistycznych diagnoz.
- Gemma 2, choć również błędna w klasyfikacji, w uzasadnieniu trafniej założyła, że problem jest powszechny i prawdopodobnie samoistnie ustąpi.
- Modele wykazały się nadmierną ostrożnością. Wolały przeszacować powagę sytuacji niż zaryzykować zbagatelizowanie realnego zagrożenia.

5 Analiza zbiorcza dokładności i mechanizmu auto-krytyki

W tej sekcji przedstawiono porównanie statystyczne obu modeli, uwzględniając ich obiektywną skuteczność oraz subiektywną ocenę własnej pracy wygenerowaną w fazie *self-critique*.

5.1 Porównanie dokładności i jakości porad

Analiza wykazała istotne różnice w poziomie pewności siebie obu systemów. Model Gemma 2 nie tylko osiągnął wyższą dokładność ogólną, ale również wyżej oceniał jakość swoich odpowiedzi.

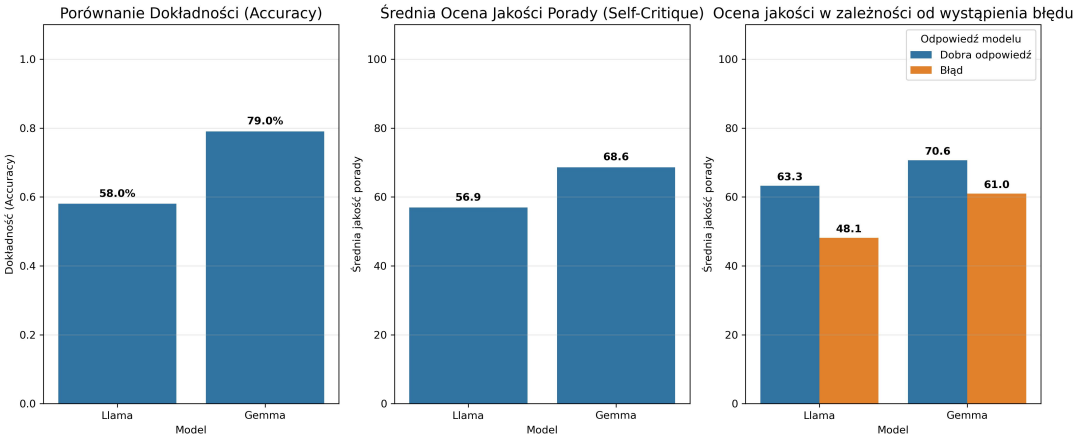

Rysunek 4: Zestawienie dokładności (Accuracy) oraz średniej oceny jakości porady.

- **Średnia ocena jakości:** Model Llama 3.1 gorzej oceniał swoją pracę (średnia **56.9**), podczas gdy Gemma 2 była znacznie bardziej pewna swoich wyników (średnia **68.6**).
- **Korelacja błędu z oceną:** W przypadku obu modeli zauważalna jest wyraźna korelacja – im lepsza ocena własna, tym mniejszy procent faktycznych błędów.

5.2 Rozkład ocen własnych i ich wiarygodność

Poniższe wykresy prezentują, jak często modele wystawiały sobie konkretne noty oraz jak te noty przekładały się na faktyczną liczbę błędnych diagnoz.

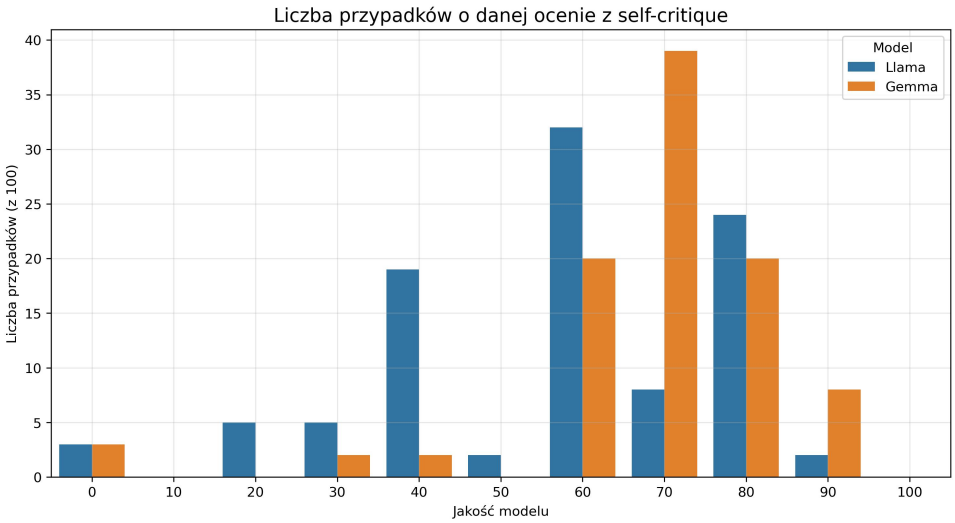

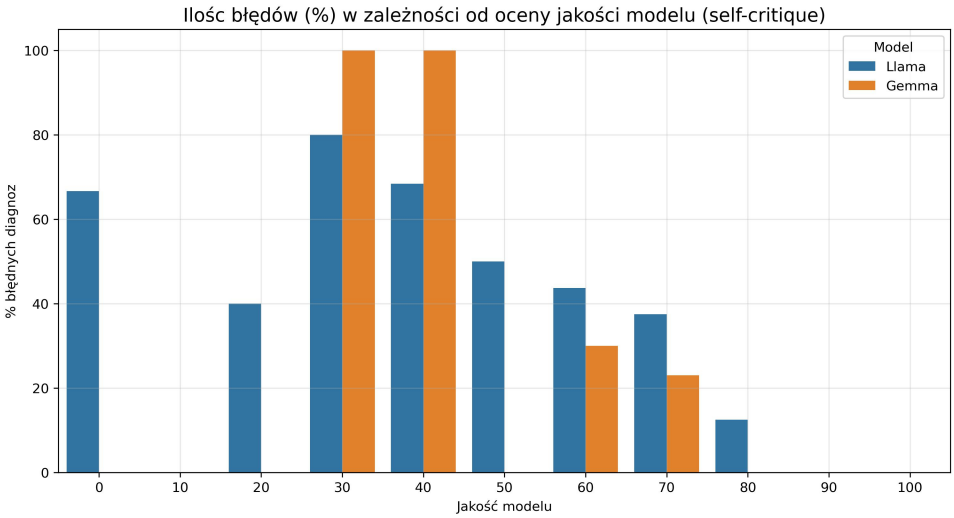

5.3 Obserwacje

- Wszystkie przypadki, które model Gemma ocenił bardzo słabo (w przedziale **30–40/100**), okazały się faktycznymi błędami, co czyni ten mechanizm wiarygodnym wskaźnikiem ostrzegawczym dla tego modelu.
- Model Llama 3.1 jest bardziej krytyczny wobec siebie i jednocześnie mniej skuteczny w klasyfikacji. Model Gemma 2 wykazuje się większą skutecznością, lecz bywa zbyt pewny siebie, co objawia się wysokimi notami własnymi nawet przy błędnych kategoriach.
- Mechanizm *self-critique* pozwala modelom na trafną identyfikację własnych pomyłek.

6 Demo i Implementacja

W ramach projektu przygotowaliśmy interaktywny notatnik Jupyter (`demo.ipynb`).

- Użytkownik może wybrać model i wpisać własny opis objawów w polu tekstowym.
- Po uruchomieniu komórki generowane jest okno HTML z diagnozą, wyjaśnieniem tekstowym oraz wizualną warstwą wyjaśnialności (podświetlone fragmenty tekstu).
- Interfejs zawiera stałe ostrzeżenie: projekt ma cel wyłącznie edukacyjny i nie jest poradą medyczną.

7 Wnioski końcowe

- Model Gemma 2 był bardziej skuteczny niż Llama 3.1, wykazuje lepszą zdolność do różnicowania powagi stanów medycznych
- Oba modele są z natury ostrożne – rzadko bagatelizują objawy, a Llama najczęściej wybiera bezpieczną opcję „DO LEKARZA”.

- Mechanizm Self-Critique jest skutecznym narzędziem do wykrywania halucynacji i błędów – niskie oceny własne modelu bardzo dobrze korelują z faktycznymi pomyłkami
- Llama jest wobec siebie bardziej krytyczna (niższe oceny własne), natomiast Gemma bywa zbyt pewna siebie, wysoko oceniając nawet błędne diagnozy.
- Wyjaśnialność poprzez podświetlanie tekstu i Chain-of-Thought znacząco ułatwia weryfikację pracy modeli przez człowieka